

Model	Method	Cancer-Myth		CREPE		Medical QA			General QA	
		FPQ ↑	NFP ↑	FPQ ↑	TPQ ↑	MQ ↑	PQ ↑	MB ↑	MMLU ↑	GSM ↑
Qwen2.5 7B	Plain	—	—	—	—	—	—	—	—	—
	Premise-review CoT	—	—	—	—	—	—	—	—	—
	PreWoMe-style	—	—	—	—	—	—	—	—	—
	Extract + Verify	—	—	—	—	—	—	—	—	—
	GEPA	—	—	—	—	—	—	—	—	—
	GEPA + text feedback	—	—	—	—	—	—	—	—	—
	GEPA + SAE feedback	—	—	—	—	—	—	—	—	—
GPT-6 Luna	Plain	—	—	—	—	—	—	—	—	—
	Premise-review CoT	—	—	—	—	—	—	—	—	—
	PreWoMe-style	—	—	—	—	—	—	—	—	—
	Extract + Verify	—	—	—	—	—	—	—	—	—
	GEPA	—	—	—	—	—	—	—	—	—
	GEPA + text feedback	—	—	—	—	—	—	—	—	—
	GEPA + SAE feedback	—	—	—	—	—	—	—	—	—
Gemma 4 12B	Plain	—	—	—	—	—	—	—	—	—
	Premise-review CoT	—	—	—	—	—	—	—	—	—
	PreWoMe-style	—	—	—	—	—	—	—	—	—
	Extract + Verify	—	—	—	—	—	—	—	—	—
	GEPA	—	—	—	—	—	—	—	—	—
	GEPA + text feedback	—	—	—	—	—	—	—	—	—
	GEPA + SAE feedback	—	—	—	—	—	—	—	—	—
Qwen3.8 27B OFF	Plain	—	—	—	—	—	—	—	—	—
	Premise-review CoT	—	—	—	—	—	—	—	—	—
	PreWoMe-style	—	—	—	—	—	—	—	—	—
	Extract + Verify	—	—	—	—	—	—	—	—	—
	GEPA	—	—	—	—	—	—	—	—	—
	GEPA + text feedback	—	—	—	—	—	—	—	—	—
	GEPA + SAE feedback	—	—	—	—	—	—	—	—	—
Qwen3.8 27B ON	Plain	—	—	—	—	—	—	—	—	—
	Premise-review CoT	—	—	—	—	—	—	—	—	—
	PreWoMe-style	—	—	—	—	—	—	—	—	—
	Extract + Verify	—	—	—	—	—	—	—	—	—
	GEPA	—	—	—	—	—	—	—	—	—
	GEPA + text feedback	—	—	—	—	—	—	—	—	—
	GEPA + SAE feedback	—	—	—	—	—	—	—	—	—

Table 2. Response quality and preservation of general QA performance

Unmeasured plan: — is not a measured score. All metrics are percentages.
 FPQ: correction; NFP/TPQ: normal-question preservation (Well ≥ 4).
 MQ: MedQA; PQ: PubMedQA; MB: Medbullets; GSM: GSM8K. No cross-dataset average.
 General QA: MMLU accuracy and GSM8K final-answer exact match; models use the same test protocol.