

Model	Method	Cancer-Myth		CREPE		Medical QA			General QA	
		FPQ ↑	NFP ↑	FPQ ↑	TPQ ↑	MQ ↑	PQ ↑	MB ↑	MMLU ↑	GSM ↑
Qwen2.5 7B	Plain	1.7 ^T	100.0 ^T	—	—	—	—	—	—	—
	DPO (FPQ + twins)	2.6 ^T	100.0 ^T	—	—	—	—	—	—	—
	SFT (FPQ + twins)	29.1 ^T	45.6 ^T	—	—	—	—	—	—	—
	SFT (same chosen)	—	—	—	—	—	—	—	—	—
	DPO (FPQ + NFP)	—	—	—	—	—	—	—	—	—
	Feature-curated DPO	—	—	—	—	—	—	—	—	—
	Ours (GEPA + SAE)	—	—	—	—	—	—	—	—	—
	GEPA + SAE + NLA	—	—	—	—	—	—	—	—	—
Gemma-3 12B	Plain	—	—	—	—	—	—	—	—	—
	SFT (same chosen)	—	—	—	—	—	—	—	—	—
	DPO (FPQ + NFP)	—	—	—	—	—	—	—	—	—
	Feature-curated DPO	—	—	—	—	—	—	—	—	—
	Ours (GEPA + SAE)	—	—	—	—	—	—	—	—	—
	GEPA + SAE + NLA	—	—	—	—	—	—	—	—	—
Gemma-2 9B	Plain	—	—	—	—	—	—	—	—	—
	SFT (same chosen)	—	—	—	—	—	—	—	—	—
	DPO (FPQ + NFP)	—	—	—	—	—	—	—	—	—
	Feature-curated DPO	—	—	—	—	—	—	—	—	—
	Ours (GEPA + SAE)	—	—	—	—	—	—	—	—	—
	GEPA + SAE + AO	—	—	—	—	—	—	—	—	—

Table S1. Training and internal-description ablations

Stored results; — means unavailable or not comparable. Values are percentages, one run.
FPQ / NFP / TPQ: Well ≥ 4. MQ / PQ / MB: MedQA / PubMedQA / Medbullets.
T: legacy 234 FPQ / 149 natural NFP; twins are synthetic training data, not test NFP.
Planned same-chosen SFT / natural-NFP DPO / feature feedback remain unmeasured.
Model versions, counts, judge/protocol differences and source hashes: result_sources.md.