

Model	Method	Cancer-Myth		CREPE		Medical QA			General QA	
		FPQ ↑	NFP ↑	FPQ ↑	TPQ ↑	MQ ↑	PQ ↑	MB ↑	MMLU ↑	GSM ↑
Qwen2.5 7B	Plain	—	—	—	—	—	—	—	—	—
	SFT (same chosen)	—	—	—	—	—	—	—	—	—
	DPO (FPQ + NFP)	—	—	—	—	—	—	—	—	—
	Feature-curated DPO	—	—	—	—	—	—	—	—	—
	GEPA + SAE feedback	—	—	—	—	—	—	—	—	—
	GEPA + SAE + NLA	—	—	—	—	—	—	—	—	—
Gemma-3 12B	Plain	—	—	—	—	—	—	—	—	—
	SFT (same chosen)	—	—	—	—	—	—	—	—	—
	DPO (FPQ + NFP)	—	—	—	—	—	—	—	—	—
	Feature-curated DPO	—	—	—	—	—	—	—	—	—
	GEPA + SAE feedback	—	—	—	—	—	—	—	—	—
	GEPA + SAE + NLA	—	—	—	—	—	—	—	—	—
Gemma-2 9B	Plain	—	—	—	—	—	—	—	—	—
	SFT (same chosen)	—	—	—	—	—	—	—	—	—
	DPO (FPQ + NFP)	—	—	—	—	—	—	—	—	—
	Feature-curated DPO	—	—	—	—	—	—	—	—	—
	GEPA + SAE feedback	—	—	—	—	—	—	—	—	—
	GEPA + SAE + AO	—	—	—	—	—	—	—	—	—

Table S1. Training and internal-description ablations

Unmeasured plan: — is not a measured score. All metrics are percentages.

FPQ: correction; NFP/TPQ: normal-question preservation (Well ≥ 4).

MQ: MedQA; PQ: PubMedQA; MB: Medbullets; GSM: GSM8K. No cross-dataset average.

General QA: MMLU accuracy and GSM8K final-answer exact match; models use the same test protocol.

NLA/AO rows require compatible checkpoints; runtime and resources remain to be checked.